

F グループ

詳しいテスト方法や実装方法まで記していてわかりやすかったと感じた。

学習量・クラス偏りでの変化を比較軸に入れているのが良いと思った。

だいぶ深堀りされていたので、私が今持っている知見ではさらなる指摘が難しい。強いて言えば、分類すべきカテゴリが所与のものである点が気になった。分析結果から新たにカテゴリを設定したりはできないのだろうか。

手法の選定理由が説明されていて、とても分かりやすい。

文章カテゴリ分類の部分では、分析・分類するテキストの数が多くなると思うので、分類や整理の管理がとても重要になると思います。

4つの手法や前処理を変えながらの比較で、より細かな検証ができそうだと感じた。
前処理の有効性や、手法の特徴などが結果から考察できるとよいと感じた。

不均衡データの作成を通して、特徴のある分類カテゴリの特定なども行えると面白いと感じた

システムを作る際に使う言語はなにか。

各手法においてナイーブベイズをベースラインとして使用するのであれば、そのほかの各手法がベースラインと比較して何を見るためのものなのかが気になりました。LSTM→Transformer では LSTM ではなく Transformer を用いることのメリットは分かったのですが、ベースラインとの比較点が分かりませんでした。

各手法に対してそれぞれ手順と前処理を説明していてわかりやすい。LSTM や transformer の性能がいいんだろうがそれでも結果が楽しみ。

ストップワードはどこまで設定するのでしょうか。設定範囲によって精度も大きく変わりそうです

一番具体的なことが決まっているグループだと感じた。この段階でここまで決まっているのは素晴らしいと思った

学習データ量を変えるという視点は面白いと思った。学習データ量が少なくても良い精度ができる方がいいから。

ライブドアニュースコーパスを利用し、複数のモデル (TF-IDF+ナイーブベイズ、LSTM、FastText、BERT) を比較するという非常に体系的で発展的な構想を提示しており、研究的完成度の高さが際立ちます。特に、学習データ量を変化させながら性能・学習効率・計算コストを比較するという設計は、実験科学的で説得力があります。加えて、ストップワード除去や活用形統一など、前処理工程が明確に定義されており、再現性の高い設計です。一方で、複数モデルを比較する際には、パラメータチューニングの公平性や、カテゴリバランスに対する補正（例：SMOTE など）にも注意が必要です。評価指標として Accuracy だけでなく、F1・Recall・Precision を併用する点も的確で、分析の多角性が担保されています。

扱うデータが長文なので、過去の文脈も考慮できる LSTM は良いなと思った。

学習の際に、使用データの件数で学習精度？を比較すると聞いたと思う。その際、使用データの 100 件や 500 件を抜粋する場合の他にも、全データ(100%)を学習させるという場合もあったと思われる。使用データの 100%で学習させた場合、テストの際の入力文はどうするのか気になった。テストの際に学習データと同じものを使うと、正解するのは当たり前になると思うので、他のデータセットなどを使うのが良いかもしれないと考えた。

4 種類の異なる手法を比較し、9 種類のニュースジャンルを分類するという構成が非常に充実しています。今後はモデルの軽量化や多言語対応の比較をしたいと思いました

四種類の手法による性能を、学習効率、計算コストで細分化して評価しているため、性能とコストのバランスがどのようになっているか明確に出ることが期待できそうです。
また、事前学習の有無で結果にどのような差が出るか興味があります。

様々な手法を用いた比較について、各モデルの特徴が実際にどのように反映されるのか楽しみです。

使用するデータセットを私は見つけられなかったので参考にしたいと思った